

Clasificación Relacional de Documentos Científicos: Un Enfoque Topológico sobre el Dataset Cora

Juan Antonio Fernández Ruiz

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla

Sevilla, España
juanafr@us.es

Nombre y apellidos alumno 2

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla

Sevilla, España
Correos electrónicos UVUS y de contacto (si distinto)

Resumen—Este documento presenta los avances preliminares en la construcción y evaluación de modelos de aprendizaje automático relacional aplicados al conjunto de datos Cora. El objetivo principal es predecir la temática de artículos científicos combinando sus atributos textuales con características topológicas extraídas de su red de citas. Hasta la fase actual de desarrollo, se ha completado el análisis exploratorio, la extracción de métricas estructurales (centralidad, clustering y comunidades) y el establecimiento de una línea base de rendimiento mediante cuatro algoritmos clásicos de clasificación. Los resultados preliminares muestran que los Árboles de Decisión logran generalizar de manera competitiva frente a modelos conexionistas y probabilísticos.

Palabras clave—Aprendizaje Automático Relacional, Teoría de Grafos, Clasificación de Nodos, Dataset Cora.

I. INTRODUCCIÓN

El análisis de datos estructurados en forma de red se ha convertido en un área de vital importancia debido a la ubicuidad de los grafos en dominios como las redes sociales, biológicas y de comunicaciones. A diferencia del aprendizaje automático tradicional, que asume la independencia entre los ejemplos, el aprendizaje relacional aprovecha las correlaciones inherentes en los enlaces entre nodos para mejorar la capacidad predictiva de los modelos.

En numerosos grafos del mundo real aparece el fenómeno conocido como *homofilia*, según el cual los nodos conectados tienden a compartir características similares. En redes de citas científicas como el dataset Cora, este comportamiento se manifiesta en que los artículos pertenecientes a una misma temática suelen citar trabajos relacionados del mismo ámbito de investigación.

Esta propiedad resulta especialmente relevante en nuestro contexto, ya que permite aprovechar no solo las características individuales de cada nodo, sino también la información estructural derivada de sus conexiones. Las *Graph Neural Networks* (GNNs) explotan precisamente esta dependencia relacional mediante mecanismos de agregación de vecindario, propagando información entre nodos próximos del grafo para mejorar tareas como la clasificación de documentos.

En este trabajo, se aborda el problema de la clasificación de nodos en redes de citación científica utilizando el conjunto de datos Cora. El enfoque adoptado consiste en la extracción manual de características topológicas para enriquecer

las propiedades nativas de los documentos. El resto de este documento detalla los preliminares teóricos (Sección II), la metodología y decisiones de diseño adoptadas hasta la fecha (Sección III), los resultados empíricos preliminares (Sección IV) y, finalmente, las conclusiones e hitos de trabajo futuro (Sección V).

II. PRELIMINARES

A. Métodos empleados

Para la representación y procesamiento de los datos relacionales se ha empleado la librería de Python *NetworkX*. Específicamente, nos apoyamos en la teoría de grafos para calcular medidas topológicas de centralidad, densidad local (coeficiente de *clustering*) y algoritmos de detección de comunidades para identificar subestructuras cohesivas. Para la etapa de modelado y clasificación, se ha empleado *Scikit-Learn*, evaluando algoritmos basados en instancias (*k-Vecinos más Cercanos*), particionado recursivo (*Árboles de Decisión*), aproximaciones probabilísticas (*Naive Bayes Gaussiano*) y modelos conexionistas (*Perceptrón Multicapa*).

B. Trabajo Relacionado

Como referencia fundamental para nuestro enfoque, destaca el trabajo de Sen *et al.* sobre clasificación colectiva en datos de redes, en el cual los autores emplean el conjunto de datos Cora para predecir la temática de los artículos basándose en la correlación de sus enlaces y propiedades. Su investigación demuestra que aprovechar la estructura subyacente de la red mejora significativamente el rendimiento frente a clasificadores tradicionales que tratan cada documento de forma independiente.

La clasificación de nodos en grafos constituye uno de los problemas más relevantes dentro del aprendizaje automático sobre estructuras relacionales. A diferencia de los enfoques tradicionales de aprendizaje supervisado, donde cada instancia se considera de manera independiente, en los grafos existe información adicional derivada de las relaciones entre nodos, lo que permite explotar dependencias estructurales durante el proceso de aprendizaje.

En muchos grafos reales aparece el fenómeno conocido como *homofilia*, según el cual los nodos conectados tienden a compartir propiedades similares. En redes de citas científicas

como el dataset Cora, esta propiedad se manifiesta en que artículos pertenecientes a áreas temáticas similares suelen citar trabajos relacionados del mismo ámbito de investigación. Como consecuencia, la estructura del grafo aporta información semántica complementaria a las características propias de cada nodo.

La clasificación de nodos puede abordarse explotando diferentes tipos de correlaciones presentes en la red. De forma general, pueden distinguirse tres fuentes principales de información: (1) los atributos propios del nodo, (2) los atributos de los nodos vecinos y (3) las etiquetas de los nodos vecinos. Mientras que los enfoques clásicos de aprendizaje automático se centran únicamente en las características individuales de cada instancia, los modelos basados en grafos incorporan además información contextual derivada de la conectividad entre nodos.

Las *Graph Neural Networks* (GNNs) explotan precisamente estas dependencias relacionales mediante mecanismos de agregación y propagación de información entre vecinos, conocidos como *message passing*. En este proceso, cada nodo actualiza iterativamente su representación interna utilizando tanto sus propias características como la información agregada de su vecindario local.

Entre las arquitecturas más relevantes destacan las *Graph Convolutional Networks* (GCN), que introducen operaciones convolucionales adaptadas a grafos mediante normalización de la matriz de adyacencia, y modelos posteriores como GraphSAGE, que permiten generalizar el aprendizaje mediante funciones de agregación inductivas.

En este trabajo se estudia el aprovechamiento de las dos primeras fuentes de correlación: los atributos propios de cada nodo y los atributos de sus vecinos dentro de la estructura del grafo. Para ello se emplea el dataset Cora, ampliamente utilizado como benchmark en tareas de clasificación de nodos sobre grafos homofílicos.

III. METODOLOGÍA

A. DATASET CORA Y ANÁLISIS EXPLORATORIO

El conjunto de datos Cora original consta de 2708 publicaciones científicas divididas en 7 clases temáticas, vinculadas mediante 5429 enlaces de citación. La matriz de propiedades nativas de los documentos está compuesta por un vocabulario binario de 1433 palabras.

El análisis exploratorio reveló una extrema dispersión en los datos textuales, con un 98.73% de ceros y un promedio de solo 18.17 palabras clave presentes por artículo. Además, se evidenció un marcado desbalanceo de clases, siendo *Neural_Networks* la clase dominante con 818 artículos, frente a temáticas marcadamente minoritarias como *Rule_Learning* con 180 instancias (Fig. 1).

Asimismo, la distribución del número de palabras activas por documento (Fig. 2) confirma la alta dispersión del espacio de atributos nativos, con una fuerte concentración en valores bajos.




Fig. 1. Distribución de clases del dataset Cora




Fig. 2. Distribución de palabras activas por artículo en Cora

B. ARQUITECTURA USADA Y EXTRACCIÓN DE CARACTERÍSTICAS

Para la representación matemática de la información, se tomó la decisión de diseño de modelar la red de citas como un grafo no dirigido. Esta arquitectura de los datos permitió la fusión de forma natural de las citas recíprocas en 5278 aristas únicas y garantizó la convergencia estructural para los algoritmos topológicos aplicados posteriormente. La distribución de grados observada en la red (Fig. 3) evidencia una topología heterogénea, coherente con la utilidad de métricas de centralidad para caracterizar la influencia estructural de cada nodo.

Para enriquecer la representación de cada publicación científica, se extrajeron tres métricas relacionales para cada




Fig. 3. Distribución de grados del grafo de citación Cora

nodo:

- **Centralidad de Intermediación:** Elegida por su alta capacidad predictiva para identificar artículos que actúan como “puentes” de información entre diversas áreas temáticas.
- **Coefficiente de Clustering:** Calculado para medir la tendencia de las publicaciones a agruparse en vecindarios densos interconectados.
- **Detección de Comunidades:** Se seleccionó el algoritmo de Louvain para agrupar latentemente el grafo, asignando a cada artículo un identificador de la comunidad subyacente descubierta basándose exclusivamente en los enlaces.

La arquitectura final de los datos de entrada consolidó las 1433 variables del texto con las nuevas características relacionales en una única matriz.

C. PROCEDIMIENTO DE ENTRENAMIENTO

Para asegurar una evaluación justa de la capacidad de generalización de los algoritmos de clasificación, el conjunto de datos se dividió utilizando la validación por retención (*hold-out*), reservando el 80% de los ejemplos para el entrenamiento de los modelos y el 20% restante para las pruebas.

Como decisión de diseño, se aplicó un muestreo estratificado durante esta partición para preservar la proporción real de las clases y evitar sesgos derivados del desbalanceo del conjunto de datos.

El ajuste óptimo de los hiperparámetros de los cuatro modelos base se estructuró mediante una búsqueda en rejilla (*GridSearchCV*). Durante este proceso, se aplicó una validación cruzada estratificada de 5 pliegues (5-fold cross validation) en el conjunto de entrenamiento para estimar el rendimiento a priori y seleccionar de forma robusta la mejor configuración de cada algoritmo.

IV. RESULTADOS

Los experimentos iniciales han tenido como propósito establecer un *baseline* evaluando los cuatro modelos clásicos con la totalidad de las variables disponibles.

TABLA I
RENDIMIENTO DE LOS MODELOS BASE EN EL CONJUNTO DE PRUEBA

Modelo	Accuracy	F1-macro	Precision (macro)	Recall (macro)
Árbol de Decisión	0.771	0.758	0.762	0.760
Perceptrón Multicapa (MLP)	0.730	0.717	0.721	0.717
Naive Bayes Gaussiano	0.452	0.428	0.437	0.422
k-Vecinos (kNN)	0.422	0.416	0.469	0.406

Análisis Crítico Inicial: El Árbol de Decisión obtiene, con diferencia, la mejor capacidad de generalización inicial (*F1-macro* de 0.758). Esto sugiere que la altísima dispersión del texto combinada con los valores topológicos requiere de reglas de corte jerárquicas estrictas para discriminar la temática de los artículos, algo en lo que fallan modelos probabilísticos ingenuos (Naive Bayes) o basados puramente en distancia métrica (kNN). La matriz de confusión de la Fig. 4 demuestra




Fig. 4. Matriz de confusión del modelo Árbol de Decisión en test

que, gracias al ajuste por *F1-macro*, el Árbol logra identificar competentemente las clases minoritarias.

El deficiente desempeño de Naive Bayes observado en nuestros experimentos (*F1-macro* de 0.428) es consistente con los hallazgos de Sen et al. (2008), quienes también demostraron que este clasificador probabilístico se ve superado significativamente por otros modelos base al aplicarse sobre la red de citas Cora

V. CONCLUSIONES

El trabajo desarrollado hasta el momento permite concluir que la integración de propiedades estructurales (centralidad y comunidades) en un clasificador de particionado jerárquico establece una línea base robusta para la predicción temática en el dataset Cora, sorteando con éxito el desbalanceo de clases y la extrema dispersión de las variables nativas.

Trabajo Futuro: Para completar el modelado definitivo, los próximos pasos de la investigación se centrarán en dos hitos:

- 1) **Análisis de Correlaciones:** Se aplicarán pruebas estadísticas para filtrar el espacio de características. Este paso eliminará palabras o métricas ruidosas que puedan inducir sobreajuste en los modelos base.
- 2) **Modelado Avanzado de Grafos:** Se explorará el aprendizaje de representaciones latentes en baja dimensión mediante la implementación de algoritmos específicos como *Node2Vec*, con el objetivo de batir el rendimiento de la línea base actual.

REFERENCIAS

- [1] P. Sen, G. Namata, M. Bilgic, L. Getoor, B. Gallagher, and T. Eliassi-Rad, "Collective Classification in Network Data," *AI Magazine*, vol. 29, no. 3, pp. 93-106, 2008.
- [2] S. Fortunato, "Community detection in graphs," *Physics Reports*, vol. 486, no. 3-5, pp. 75-174, 2010.