

Clasificación Relacional de Documentos Científicos

Un enfoque topológico sobre el dataset Cora

Inteligencia Artificial – Ingeniería del Software · Universidad de Sevilla
· 2025/2026

Juan Antonio Fernández Ruiz

juanafra@us.es

Eulogio Reyes Díaz

eulreydia@alum.us.es

DATASET: CORA

2708 PUBLICACIONES · 5429 CITACIONES · 7 CATEGORÍAS



Aprendizaje Automático Relacional


En el aprendizaje supervisado clásico, las instancias se tratan como **independientes**. En el aprendizaje relacional, se explotan las **dependencias estructurales** entre nodos conectados para mejorar la capacidad predictiva.



En redes de citación como Cora, los documentos científicos forman un **grafo**: la topología contiene información semántica complementaria a los atributos textuales.



Notas para el presentador: Destacar el contraste entre el enfoque clásico (instancias independientes) y el relacional (instancias conectadas). Enfatizar que en Cora los documentos forman un grafo de citas donde la estructura aporta información semántica adicional.



¿Qué queremos clasificar?



Objetivo principal

Clasificar documentos del **dataset Cora** en sus 7 categorías temáticas explotando la estructura del grafo de citas.

Pregunta de investigación

¿Mejora la información relacional del grafo el rendimiento de clasificadores clásicos?

Estrategia de comparación


- Características topológicas manuales (centralidades, clustering, comunidades)
- Representaciones latentes densas con Node2Vec (*desarrollado en parte posterior*)



Notas para el presentador: Explicar que el objetivo es comprobar si la información relacional mejora la clasificación. Mencionar que se compararán dos enfoques, pero que Node2Vec se desarrollará en una parte posterior de la presentación.

Distribución de Clases: Dataset Desbalanceado

Categoría



Desbalance significativo

Clase mayoritaria: Neural Networks – 818 documentos

Clase minoritaria: Rule Learning – 180 documentos

Proporción aproximada de **8:2** entre extremos.



La *accuracy* puede ser engañosa: un modelo trivial que siempre prediga la clase mayoritaria obtendría alta exactitud. Por ello, se usará **F1-macro** como métrica principal de evaluación.



Notas para el presentador: Explicar que el desbalanceo es un problema real que afecta a la evaluación. Justificar por qué *accuracy* no es suficiente y por qué se usará F1-macro, que penaliza el mal rendimiento en clases minoritarias.

Dataset Cora: Red de Publicaciones Científicas

2708

Nodos

Publicaciones científicas

5429

Aristas

Enlaces de citación

7

Categorías

Temáticas de clasificación

1433

Atributos


Palabras clave binarias por artículo

Cada **nodo** es un artículo científico; cada **arista** representa una relación de citación. Los artículos están etiquetados en 7 categorías temáticas como *Neural Networks*, *Probabilistic Methods* o *Genetic Algorithms*.



Notas para el presentador: Presentar Cora como benchmark estándar en aprendizaje sobre grafos. Destacar que cada artículo tiene tanto atributos textuales (palabras clave) como relaciones estructurales (citas).

Atributos Textuales: Alta Sparsity



0	0	0	0
0	0	1	0
0	1	0	0
0	0	0	1

Representación textual

Cada documento se codifica con **1433 atributos binarios** que indican la presencia o ausencia de palabras clave.

- ❑ Con tan poca información textual activa, clasificar solo con palabras sueltas resulta muy complejo. Esto **fundamenta el uso de información relacional del grafo**.

98.73% sparsity

La inmensa mayoría de los valores son ceros


~18 palabras activas

Media de palabras clave por artículo



Notas para el presentador: Destacar que la extrema dispersión de la matriz textual (98.73% de ceros) limita la capacidad de clasificación basada solo en atributos de palabras. Este es el argumento principal para incorporar información estructural del grafo.

Estructura del Grafo de Citas: Ley de Potencias



Conectividad asimétrica


La distribución de grados sigue una **Ley de Potencias**: $P(k) \sim k^{-\gamma}$

- **Grado promedio:** 2.87 conexiones
- **Mayoría periférica:** 1-3 citas
- **Hubs centrales:** hasta 166 conexiones

Unos pocos artículos pioneros actúan como **referencias centrales** que conectan toda la red científica.

 **Notas para el presentador:** Explicar que la distribución de grados no es uniforme sino que sigue una ley de potencias. Destacar la existencia de hubs (artículos muy citados) y cómo la mayoría de artículos están en la periferia con pocas conexiones.

Homofilia: La Clave Estructural



¿Qué es la homofilia?

En redes de citación, **nodos conectados tienden a compartir temática**. Los artículos citan preferentemente a trabajos de su misma área.

Implicación para la clasificación

La categoría de un documento puede inferirse no solo por sus **palabras**, sino también por sus **conexiones** en el grafo.



La topología de citas codifica **información semántica** complementaria a los atributos textuales.


Por ello, el siguiente paso del proyecto consiste en **transformar la estructura del grafo en características relacionales** útiles para los modelos de aprendizaje automático.



Notas para el presentador: Explicar el concepto de homofilia y cómo justifica usar información estructural del grafo para clasificación. Usar esta diapositiva como transición natural hacia la siguiente parte de la presentación, donde se describirá la ingeniería de características relacionales.

De Grafo a Variables Predictivas


El objetivo de esta fase es transformar la estructura del grafo de citas en variables numéricas y categóricas aprovechables por clasificadores clásicos. Cada nodo representa un documento científico; las relaciones de cita permiten calcular propiedades topológicas que enriquecen los atributos textuales originales.



El esquema resume la transformación: del grafo crudo a una matriz de características lista para modelado supervisado.



Nota para el presentador: Enfatizar que la idea central es complementar el texto con estructura de red. Los atributos textuales solos son insuficientes por la alta dispersión (~98% de ceros).



Métricas Relacionales Calculadas

Cuatro características topológicas capturan aspectos complementarios de la estructura de la red de citas.



Centralidad de Grado

Cuantifica cuántas conexiones directas tiene un nodo en el grafo.



Betweenness

Mide si un nodo actúa como puente entre distintas zonas del grafo.



Coefficiente de Clustering

Refleja la densidad de conexiones en el vecindario local del nodo.



Comunidad Louvain

Identifica grupos de nodos densamente conectados entre sí.



Nota para el presentador: Destacar que cada métrica captura un aspecto estructural distinto: conectividad directa, papel de puente, cohesión local y agrupación comunitaria.

Patrones Topológicos Observados



Hallazgos clave del análisis

- Louvain detectó **104 comunidades topológicas** frente a las 7 clases temáticas originales, revelando subnichos de investigación compactos.
- Los **hubs** presentan alta centralidad pero bajo clustering: son citados por ramas diversas que no interactúan entre sí.
- Un grupo reducido de artículos actúa como **puentes estructurales** (alta betweenness), conectando áreas distintas.



Mensaje clave: La estructura del grafo contiene información semántica sobre la temática de los artículos.



Nota para el presentador: La figura muestra cómo las comunidades detectadas solo por citas reflejan agrupaciones temáticas reales. Los hubs con bajo clustering son nodos interdisciplinarios.

Matriz Final de Características Manuales

Las cuatro métricas relacionales se alinearon con los atributos textuales originales de cada documento, conformando el espacio de entrada para los modelos supervisados.

1433 atributos textuales

Variables binarias de presencia de palabras clave por documento.

+ 4 características relacionales

Grado, betweenness, clustering y comunidad Louvain.

= 1437 variables predictivas

Espacio de características listo para entrenar clasificadores clásicos.

❏ **Nota para el presentador:** Subrayar que la matriz combina información léxica (texto) con información estructural (grafo). No mencionar aún resultados de modelos.

Validación Estadística de las Métricas

Antes del modelado, se analizó si las métricas relacionales presentaban relación con las clases temáticas mediante correlaciones y tests de asociación.

Correlaciones entre métricas numéricas

Par de variables	Pearson	Spearman
Grado - Betweenness	0.8746	0.7610
Grado - Clustering	-0.0357	0.3849
Betweenness - Clustering	-0.1038	-0.0525

Interpretación

- Grado y betweenness presentan correlación alta, pero no son equivalentes: uno mide conectividad directa y el otro papel de puente.
- El clustering aporta una perspectiva estructural diferente, relacionada con la densidad local del vecindario.
- Ninguna variable se considera redundante; se conservan las cuatro para el modelado.

❏ **Nota para el presentador:** La correlación alta entre grado y betweenness no implica redundancia: capturan roles estructurales distintos en el grafo.

Asociación entre Topología y Clase

Tests estadísticos aplicados

Test / Métrica	Resultado
Kruskal-Wallis – Grado	$p = 3.94 \times 10^{-8}$
Kruskal-Wallis – Betweenness	$p = 4.78 \times 10^{-4}$
Kruskal-Wallis – Clustering	$p = 4.24 \times 10^{-5}$
χ^2 Comunidad Louvain vs. Clase	$\chi^2 = 9375.29$, $p \approx 0.0$
V de Cramér	0.7596

Conclusiones

- Las tres métricas relacionales muestran diferencias significativas entre clases ($p < 0.05$).
- La asociación entre comunidad Louvain y clase real es **muy fuerte** (V de Cramér = 0.7596).



La topología aporta señal predictiva: las comunidades detectadas solo con la estructura de citas están fuertemente asociadas a las categorías temáticas reales.



Nota para el presentador: Este resultado justifica incorporar las métricas relacionales al espacio predictivo. La V de Cramér cercana a 0.76 indica asociación muy fuerte.

Protocolo Experimental

El marco de validación garantiza generalización y evita fugas de información antes de comparar modelos.

01

Partición estratificada 80/20

2166 instancias para entrenamiento, 542 para test. Semilla fija `random_state=42`.

03

GridSearchCV + 5-Fold CV

Búsqueda en rejilla con validación cruzada estratificada de 5 pliegues.

02

Pipelines con StandardScaler

Normalización aplicada de forma independiente dentro de cada partición de validación.

04

Métrica objetivo: F1-macro

Promedio no ponderado del F1 por clase, adecuado para el desbalance del dataset.




Próximo paso: Con este protocolo se compararon clasificadores clásicos sobre características manuales y, posteriormente, sobre representaciones latentes con Node2Vec.



Nota para el presentador: Cerrar enfatizando que el protocolo es idéntico en ambos escenarios (manual y Node2Vec), lo que hace la comparativa justa y atribuible únicamente a la representación de entrada.

Dos estrategias de representación



Protocolo experimental común

- Holdout estratificado 80/20
- GridSearchCV con Stratified 5-Fold CV
- Métrica principal: **F1-macro**
- Semilla fija: random_state=42



Nota para el presentador: Ambos enfoques comparten exactamente el mismo protocolo experimental; solo cambia la codificación de entrada.

Cuatro clasificadores clásicos



kNN

k-Vecinos más Cercanos. Basado en distancias geométricas entre ejemplos.



Árbol de Decisión

Reglas de corte sobre variables. Robusto ante alta dimensionalidad dispersa.



Naive Bayes

Clasificador probabilístico gaussiano. Ligero y rápido.



MLP

Perceptrón Multicapa. Capaz de capturar no linealidades complejas.

Se seleccionan modelos clásicos de *scikit-learn* para garantizar **interpretabilidad, comparabilidad directa y pipelines ligeros y reproducibles**.



Nota para el presentador: Los modelos clásicos permiten aislar el efecto de la representación de características sin introducir complejidad de GNNs.

Rendimiento con características manuales (1437 variables)




Tabla de resultados en test

Modelo	F1-macro
Árbol de Decisión	0.7588
MLP	0.7171
Naive Bayes	0.4281
kNN	0.4168

Mejor baseline: Árbol de Decisión con F1-macro = 0.7588. Las características manuales aportan señal, pero el espacio es muy disperso (98,73% de ceros).



Nota para el presentador: Destacar la caída de kNN y Naive Bayes; se explicará en la siguiente diapositiva.


¿Por qué funciona mejor el Árbol de Decisión?

✓ Árbol de Decisión — ventaja

- Opera con reglas de corte sobre variables binarias
- No depende de distancias euclídeas
- Se adapta bien a espacios dispersos de alta dimensión

✗ kNN — limitación geométrica

- Espacio de **1437 dimensiones** con ~98% de ceros
- Las distancias euclídeas pierden significado (*curse of dimensionality*)
- Los nodos se vuelven casi equidistantes → sin poder discriminativo



La maldición de la dimensionalidad explica el bajo rendimiento de kNN en el enfoque manual.



Nota para el presentador: Esta limitación geométrica es la motivación clave para probar Node2Vec.

Representaciones latentes con Node2Vec



Node2Vec transforma el grafo en vectores densos que capturan homofilia y proximidad estructural.

Configuración del algoritmo

- **dimensions** = 64
- **walk_length** = 30 saltos
- **num_walks** = 200 caminatas/nodo
- **window** = 10

¿Qué captura Node2Vec?

- Proximidad estructural y **homofilia** del grafo
- Patrones de vecindad semántica entre nodos
- Sustituye 1437 variables dispersas por **64 dimensiones densas**



Nota para el presentador: Node2Vec comprime la información topológica del grafo en un espacio vectorial denso y semánticamente rico.

Rendimiento con embeddings Node2Vec (64 dimensiones)

Modelo




Tabla de resultados en test

Modelo	F1-macro
kNN	0.8680
MLP	0.8480
Naive Bayes	0.7600
Árbol de Decisión	0.6890

✓ **kNN pasa al liderazgo global** con F1-macro = 0.8680. Node2Vec beneficia especialmente a modelos basados en distancia geométrica.




Nota para el presentador: Obsérvese el cambio radical en el ranking: kNN pasa de último a primero.

F1-macro en test: Manual vs Node2Vec

Manual (1437 variables)

Node2Vec (64 dimensiones)



Mayor mejora

kNN: **+0.4512** puntos de F1-macro al cambiar a Node2Vec.

Mejor modelo global

kNN + Node2Vec supera al mejor baseline manual en **+0.1092** puntos.

Excepción

Árbol de Decisión pierde ventaja al dejar de operar sobre variables binarias directas.



Nota para el presentador: La representación latente captura mejor la estructura relacional del grafo, beneficiando a kNN, MLP y Naive Bayes.

Modelo definitivo: kNN + Node2Vec

Modelo seleccionado

kNN + Node2Vec

F1-macro en test: **0.8680**

CV: $0.8445 \cdot \Delta = +0.0235$

Artefacto persistido:

`modelo_definitivo_kNN_Node2Vec.joblib`

Justificación de la selección


- Mejor F1-macro global entre todos los escenarios evaluados
- Brecha CV-Test dentro del umbral de tolerancia ($\Delta \leq 0.03$)
- Los embeddings densos restauran el significado de la distancia euclídea
- Pipeline ligero, reproducible y trazable

Próximos pasos (trabajo futuro)

- Comparar con GCN y GraphSAGE
- Ampliar evaluación a CiteSeer y PubMed
- Estudiar calibración de probabilidades para despliegue

❏ Nota para el presentador: Esta diapositiva cierra la sección de resultados. La conclusión general se presentará en la parte final de la defensa.

Conclusiones Principales



El grafo codifica información semántica

La estructura de citas contiene señal discriminativa para clasificar documentos científicos más allá de los atributos textuales.

Línea base sólida con métricas manuales

Árbol de Decisión lideró con **F1-macro = 0.7588** sobre 1437 variables (1433 palabras clave + 4 métricas topológicas).

Node2Vec + kNN: modelo definitivo

Embeddings densos de 64 dimensiones elevaron el **F1-macro a 0.8680** (+11 puntos). Las representaciones latentes capturan mejor la homofilia y la estructura relacional del grafo.

Limitaciones y Líneas Futuras

Limitaciones

- Sin implementación de GCN ni GraphSAGE.
- Rendimiento condicionado a la calidad de la estructura de citas.
- Las métricas manuales no capturan toda la complejidad del grafo.

Próximos pasos

- Comparar con Graph Neural Networks.
- Explorar más configuraciones de Node2Vec.
- Evaluar en otros datasets (CiteSeer, PubMed).
- Analizar interpretabilidad de comunidades detectadas.

«No solo importa qué características tiene un nodo, sino también cómo se conecta con el resto del grafo.»