

Clasificación Relacional de Documentos Científicos: Un Enfoque Topológico sobre el Dataset Cora

Juan Antonio Fernández Ruiz

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
juanafr@us.es

Eulogio Reyes Díaz

Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
eulreydia@alum.us.es

Resumen—Este trabajo presenta una investigación completa de clasificación relacional de nodos sobre el dataset Cora, estructurada en ocho tareas consecutivas: análisis exploratorio, ingeniería de características relacionales, validación estadística, modelado base, validación de hiperparámetros, selección de modelo, control de limpieza/reproducibilidad y modelado con embeddings Node2Vec. A partir de una línea base con 1437 variables manuales, se comparan cuatro clasificadores clásicos mediante *holdout* estratificado, *GridSearchCV* y validación cruzada de 5 pliegues. Los resultados muestran que la representación latente en 64 dimensiones mejora de forma sustancial el rendimiento global: el mejor modelo pasa de un *F1-macro* de 0.7588 (Árbol de Decisión) a 0.8680 (kNN + Node2Vec). El informe integra evidencia cuantitativa, figuras de soporte y discusión metodológica para justificar la selección final del modelo.

Palabras clave—Aprendizaje Automático Relacional, Teoría de Grafos, Clasificación de Nodos, Dataset Cora.

I. INTRODUCCION

El análisis de datos estructurados en forma de red es una línea central del aprendizaje automático actual, debido a la presencia de grafos en dominios científicos, sociales y biológicos. A diferencia del aprendizaje supervisado clásico, donde las instancias se tratan como independientes, el aprendizaje relacional explota dependencias estructurales entre nodos conectados para mejorar la capacidad predictiva.

En numerosos grafos reales aparece el fenómeno de *homofilia*: nodos conectados tienden a compartir propiedades similares. En redes de citación científica como Cora, esta propiedad se traduce en que publicaciones de una misma temática presentan patrones de citación afines.

Este trabajo estudia esa estructura desde dos perspectivas complementarias: (i) características topológicas manuales calculadas con teoría de grafos y (ii) representaciones latentes aprendidas con Node2Vec. El objetivo es cuantificar en qué medida la codificación relacional incrementa el rendimiento de clasificadores clásicos de *scikit-learn*.

La contribución principal es una evaluación de extremo a extremo, organizada en ocho tareas, con trazabilidad completa de métricas y artefactos. La Sección II resume fundamentos y trabajo relacionado; la Sección III describe metodología y pipeline experimental; la Sección IV presenta resultados cuantitativos y análisis crítico; la Sección V discute implicaciones y limitaciones; y la Sección VI cierra con conclusiones y líneas futuras.

II. FUNDAMENTACION Y TRABAJO RELACIONADO

A. Marco teórico

Para el procesamiento estructural se utilizó *NetworkX*, calculando centralidad de grado, centralidad de intermediación, coeficiente de *clustering* y comunidades de Louvain. Para el modelado supervisado se empleó *scikit-learn* con cuatro familias de clasificadores: *k*-Vecinos más Cercanos, Árboles de Decisión, *Naive Bayes* Gaussiano y Perceptrón Multicapa.

La literatura sobre clasificación de nodos distingue tres fuentes de señal: atributos del nodo, atributos del vecindario y etiquetas vecinas. En este trabajo se explotan de forma directa las dos primeras, evitando fugas de información de etiquetas en inferencia.

B. Trabajo relacionado

Como referencia fundamental, Sen *et al.* [1] muestran que la estructura de red mejora la clasificación colectiva en Cora frente a enfoques puramente atributivos. En aprendizaje de representaciones, Node2Vec [3] propone caminatas sesgadas para capturar equivalencia estructural y homofilia en embeddings densos. En paralelismo, las arquitecturas GCN [4] y GraphSAGE [5] consolidan la propagación de mensajes como base de modelos neuronales sobre grafos.

Nuestro enfoque no implementa GNNs, pero se apoya en el mismo principio: la topología contiene información semántica complementaria. La ventaja práctica es mantener pipelines ligeros y reproducibles con herramientas clásicas, comparando de forma transparente características manuales frente a representaciones latentes.

III. METODOLOGIA

A. Pipeline de trabajo (8 tareas)

La investigación se ejecutó en ocho tareas consecutivas:

- T1.3: EDA de Cora y caracterización inicial de distribuciones.
- T1.4: extracción de características relacionales topológicas.
- T1.5: validación estadística de asociación entre topología y clases.
- T2.1: entrenamiento y evaluación de cuatro modelos base.




Fig. 1. Distribucion de clases del dataset Cora.




Fig. 2. Distribucion de palabras activas por articulo en Cora.

- T2.2: validacion de hiperparametros y analisis de generalizacion.
- T2.3: seleccion de modelo entre enfoques manuales y latentes.
- T2.4: limpieza, consistencia y control de reproducibilidad.
- T2.5: aprendizaje latente con Node2Vec y reevaluacion completa.

La Tabla I resume la trazabilidad entre tareas, objetivos y salidas, lo que permite auditar de forma directa el aporte de cada etapa al resultado final.

TABLA I
TRAZABILIDAD DE TAREAS, OBJETIVO Y SALIDA PRINCIPAL

Tarea	Objetivo	Salida principal
T1.3	EDA del dataset Cora	Figuras de distribucion de clases, palabras y grados
T1.4	Ingenieria relacional	Matriz consolidada con 1437 variables
T1.5	Validacion estadistica	CSV de Kruskal, correlaciones y asociacion comunidad-clase
T2.1	Linea base supervisada	Metricas CV/test de 4 modelos y modelo base persistido
T2.2	Validacion de ajuste	Analisis de brecha CV-test y consistencia de seleccion
T2.3	Seleccion final	Comparativa manual vs Node2Vec y eleccion del modelo definitivo
T2.4	Control de limpieza	Homogeneizacion de semillas y estructura de artefactos
T2.5	Embeddings relacionales	Metricas CV/test con Node2Vec y modelo final persistido




Fig. 3. Distribucion de grados del grafo de citacion Cora.




Fig. 4. Subgrafo ego del nodo con mayor conectividad. Ilustra estructura local densa.

B. Dataset Cora y analisis exploratorio

Cora contiene 2708 publicaciones, 5429 enlaces de citacion y 7 clases tematicas. La matriz nativa tiene 1433 atributos binarios de palabras clave. El EDA mostro un espacio extremadamente disperso (98.73% de ceros, 18.17 palabras activas de media por documento) y desbalanceo de clases.

C. Ingenieria de características relacionales

Se modelaron las citas como grafo no dirigido para consolidar conectividad local y obtener medidas estables para clasificacion. Sobre cada nodo se calcularon: centralidad de

grado, centralidad de intermediacion, coeficiente de *clustering* e identificador de comunidad Louvain.

La matriz final manual combina 1433 atributos textuales y 4 relacionales (1437 variables). En paralelo, T2.5 aprende una codificacion densa de 64 dimensiones con Node2Vec (*walk_length*=30, *num_walks*=200, *dimensions*=64).

D. Protocolo experimental

Se utilizo particion *holdout* estratificada 80/20 y validacion cruzada estratificada de 5 pliegues en entrenamiento. La seleccion de hiperparametros se realizo con *GridSearchCV* optimizando *F1-macro*. Se reportan *accuracy*, precision macro, recall macro y *F1-macro*, priorizando esta ultima por el desbalance de clases.

E. Configuraciones optimas seleccionadas

La Tabla II documenta las configuraciones optimas encontradas por *GridSearchCV*. Esta tabla es clave para reproducibilidad y para interpretar por que cambia el rendimiento al pasar de variables manuales a embeddings.

TABLA II
MEJORES HIPERPARAMETROS POR ESTRATEGIA DE REPRESENTACION

Escenario	Modelo	Mejor configuracion
Manual	ArbolDecision	criterion=gini, max_depth=20,
Manual	MLP	min_samples_split=5, alpha=0.001,
Manual	NaiveBayes	hidden_layer_sizes=(64), lr=0.01
Manual	kNN	var_smoothing=10 ⁻⁸
Node2Vec	kNN	n_neighbors=3, p=2, weights=distance
Node2Vec	MLP	n_neighbors=7, p=2, weights=distance
Node2Vec	NaiveBayes	hidden_layer_sizes=(64), alpha=0.0001, lr=0.001
Node2Vec	ArbolDecision	var_smoothing=10 ⁻¹¹
Node2Vec	ArbolDecision	criterion=gini, max_depth=10,
Node2Vec	ArbolDecision	min_samples_split=5

IV. RESULTADOS

A. Modelos base con características manuales (T2.1)

La Tabla III resume el rendimiento en test para las 1437 variables manuales. El Arbol de Decision fue el mejor modelo base con *F1-macro*=0.7588.

TABLA III
RESULTADOS EN TEST PARA MODELOS BASE (T2.1, CARACTERISTICAS MANUALES)

Modelo	Accuracy	Precision	Recall	F1-macro
ArbolDecision	0.7712	0.7628	0.7603	0.7588
MLP	0.7306	0.7212	0.7179	0.7171
NaiveBayes	0.4520	0.4380	0.4223	0.4281
kNN	0.4225	0.4696	0.4063	0.4168

Este bloque confirma que las características manuales aportan señal relacional útil, pero también evidencia limitaciones de un espacio de entrada muy disperso para modelos basados en distancia.




Fig. 5. Matriz de confusión del mejor modelo base (Arbol de Decision, T2.1).

B. Validación estadística relacional (T1.5)

Las pruebas no paramétricas de Kruskal-Wallis muestran diferencias significativas entre clases para las tres métricas relacionales (Tabla IV).

TABLA IV
SIGNIFICANCIA POR CLASE DE MÉTRICAS RELACIONALES (T1.5)

Métrica	Estadístico	p-valor
Centralidad de grado	45.3779	3.94×10^{-8}
Centralidad de intermediación	24.2084	4.78×10^{-4}
Coeficiente de clustering	29.8284	4.24×10^{-5}

Además, la asociación entre comunidades Louvain y clase es muy alta ($\chi^2 = 9375.29$, $p < 10^{-6}$, V de Cramer = 0.7596), lo que respalda que la estructura del grafo codifica información temática relevante. En correlaciones bivariadas, grado e intermediación presentan asociación fuerte (Pearson 0.8746; Spearman 0.7610), mientras que *clustering* captura una señal complementaria menos colineal.

C. Representaciones latentes con Node2Vec (T2.5)

La Tabla V compara el rendimiento *F1-macro* en test entre el enfoque manual y Node2Vec. La mejora más marcada aparece en kNN, que pasa de 0.4168 a 0.8680.

El cambio de ranking entre algoritmos es coherente con teoría: en espacios densos y de menor dimensión, la distancia euclídea recupera significado y beneficia a kNN; en cambio, el Arbol de Decision pierde ventaja al dejar de operar sobre variables binarias de corte directo.

TABLA V
COMPARATIVA DE F1-MACRO EN TEST: MANUAL (1437) VS NODE2VEC (64)

Modelo	Manual	Node2Vec
kNN	0.4168	0.8680
MLP	0.7171	0.8480
NaiveBayes	0.4281	0.7600
ArbolDecision	0.7588	0.6890




Fig. 6. Matriz de confusión del mejor modelo global (kNN + Node2Vec, T2.5).

D. Generalización y selección final (T2.2-T2.3)

La selección final considera desempeño y estabilidad. En T2.1, la brecha entre CV y test del Arbol de Decisión fue pequeña (0.7477 en CV frente a 0.7588 en test). En T2.5, kNN obtuvo el mejor compromiso global (CV=0.8445, test=0.8680), con mejora absoluta de 0.1092 respecto al mejor baseline manual en test.

En consecuencia, el modelo definitivo del proyecto es **kNN con embeddings Node2Vec**, persistido en los artefactos de T2.5 y reutilizado en la tarea de selección final.

E. Comparativa CV vs Test en ambos escenarios

Para evitar sesgos por comparaciones parciales, la Tabla VI alinea el *F1-macro* de validación cruzada con el de test para todos los modelos en los dos escenarios.

Los deltas moderados indican ausencia de sobreajuste severo en el conjunto de configuraciones seleccionadas. La única caída pequeña (NaiveBayes con Node2Vec) se mantiene dentro de un margen reducido y no compromete la conclusión principal del estudio.

TABLA VI
COMPARACION DE GENERALIZACION (CV VS TEST)

Escenario-Modelo	F1-CV	F1-Test	Delta
Manual-ArbolDecision	0.7477	0.7588	+0.0111
Manual-MLP	0.7057	0.7171	+0.0114
Manual-NaiveBayes	0.4081	0.4281	+0.0200
Manual-kNN	0.3897	0.4168	+0.0271
Node2Vec-kNN	0.8445	0.8680	+0.0235
Node2Vec-MLP	0.8396	0.8480	+0.0084
Node2Vec-NaiveBayes	0.7645	0.7600	-0.0045
Node2Vec-ArbolDecision	0.6749	0.6890	+0.0141

F. Analisis por clases del modelo final

La matriz de confusión de la Fig. 6 muestra una diagonal dominante en casi todas las clases. Cualitativamente, las categorías con patrones más específicos de citación (por ejemplo, *Case_Based* y *Genetic_Algorithms*) aparecen con menor confusión cruzada, mientras que clases conceptualmente cercanas (como *Theory* y *Neural_Networks*) concentran errores residuales. Este patrón es consistente con la intuición de que Node2Vec preserva vecindades estructurales y mejora especialmente donde la homofilia local es más fuerte.

V. DISCUSION

Los resultados validan la hipótesis central del trabajo: la topología de citas de Cora aporta información discriminativa que no queda plenamente capturada por los atributos textuales binarios. La evidencia estadística de T1.5 y la ganancia de rendimiento de T2.5 convergen en esa conclusión.

Desde una perspectiva metodológica, el pipeline en ocho tareas permitió separar claramente construcción de características, entrenamiento, validación y selección, reduciendo decisiones ad hoc. Este desacoplamiento facilita trazabilidad, comparabilidad entre enfoques y mantenimiento del código.

Como limitación, la tarea T1.5 no fue reejecutada en la sesión final, aunque sus salidas están persistidas en CSV y fueron utilizadas para el análisis. Por ello, la reproducibilidad inmediata de esa tarea queda condicionada a un rerun de notebook en entorno limpio, mientras que T2.1-T2.5 mantienen artefactos consistentes y verificables.

Finalmente, aunque el enfoque actual evita la complejidad de GNNs, los resultados sugieren que una comparativa futura con GCN y GraphSAGE podría cuantificar la brecha entre modelos clásicos con embeddings y arquitecturas neuronales sobre grafos.

A. Lectura integrada de los ocho hitos

Una aportación relevante de este trabajo no es solo el resultado final, sino la secuencia de decisiones experimentales. T1.3 y T1.4 establecen el contexto de dificultad: alta sparsidad en atributos textuales y estructura de grafo con heterogeneidad de conectividad. Esta combinación explica por qué un enfoque puramente lexical suele degradarse en clases minoritarias.

T1.5 actúa como puente inferencial entre análisis descriptivo y modelado: al confirmar diferencias estadísticamente significativas entre clases en métricas relacionales, legítima que la

topologia se incorpore como parte del espacio predictivo y no solo como visualizacion exploratoria. T2.1 y T2.2, en cambio, definen una linea base robusta con controles de generalizacion y evitan seleccionar por una unica metrica puntual.

La pareja T2.3-T2.5 cierra el ciclo de investigacion con una comparativa directa entre dos representaciones de datos. Esta comparativa es metodologicamente fuerte porque mantiene constantes particion, metrica objetivo y familia de modelos, alterando solo la codificacion de entrada. En esas condiciones, la mejora de kNN se puede atribuir principalmente a la calidad del embedding y no a un cambio de protocolo de evaluacion.

En terminos de disenio experimental, T2.4 garantiza que el resultado sea defendible: convenciones de guardado, semillas y consistencia de scripts reducen fragilidad del proceso y permiten trazabilidad para revisiones externas o futuras iteraciones del proyecto.

B. Implicaciones practicas y transferencia

Los hallazgos tienen implicaciones claras para escenarios reales de mineria de literatura cientifica. Cuando el texto esta representado por vectores binarios de alta dimension, la distancia entre documentos puede volverse poco informativa. El uso de embeddings topologicos densos permite recuperar una nocion de vecindad util para tareas de clasificacion, recomendacion de lecturas relacionadas y apoyo a sistemas de descubrimiento de conocimiento.

Ademas, la mejora observada no depende de arquitecturas profundas complejas: se obtiene con pipelines ligeros y modelos clasicos de coste computacional moderado. Esto abre una via pragmatica para equipos que necesitan soluciones explicables, con menor coste de mantenimiento y con infraestructura de ejecucion limitada frente a despliegues de GNN a gran escala.

Desde una perspectiva de gobierno del dato, la separacion entre artefactos por tarea facilita auditoria y control de versiones de modelos. Este enfoque es particularmente util en entornos academicos o institucionales donde la justificabilidad del resultado es tan importante como la metrica alcanzada.

C. Linea de validacion futura

Para reforzar el cierre cientifico del trabajo, la siguiente iteracion deberia priorizar tres bloques. Primero, validacion estadistica entre clasificadores finales con test pareados sobre predicciones para confirmar si la mejora de Node2Vec es estadisticamente significativa muestra a muestra. Segundo, evaluacion de robustez bajo particiones repetidas o *repeated stratified k-fold* para medir variabilidad de desempeno y sensibilidad a la muestra de entrenamiento. Tercero, comparativa externa en otros benchmarks de citacion con propiedades topologicas distintas para evaluar transferencia.

Tambien es recomendable incorporar metricas orientadas a clase minoritaria, como *macro recall* objetivo o curvas precision-recall por etiqueta, cuando el uso final penalice especialmente falsos negativos en categorias poco frecuentes. Esta extension convertiria el pipeline actual en una base mas proxima a un flujo de *MLOps* para grafos academicos.

VI. REPRODUCIBILIDAD Y AMENAZAS A LA VALIDEZ

A. Reproducibilidad experimental

El pipeline mantiene semillas fijas (*random_state=42*) y estructura de artefactos por timestamp para facilitar reruns y auditoria. Las metricas de T2.1 y T2.5 se recuperan desde CSVs persistidos, y los modelos seleccionados se almacenan en formato *joblib*. Esta estrategia reduce riesgo de perdida de contexto y permite reconstruir el flujo de decisiones desde datos crudos hasta modelo final.

B. Amenazas a la validez

Se identifican cuatro riesgos principales. Primero, validez interna: la tarea T1.5 no fue reejecutada en la sesion final y su analisis depende de salidas persistidas. Segundo, validez externa: Cora es un benchmark pequeno y homofilico; resultados pueden variar en grafos heterofilicos. Tercero, validez de constructo: se evaluan metricas macroagregadas y no costos de error especificos por clase para un dominio de aplicacion concreto. Cuarto, validez estadistica: no se aplicaron pruebas de significancia entre clasificadores finales (por ejemplo, test de McNemar), por lo que la comparativa se centra en magnitudes de desempeno y consistencia CV-test.

VII. CONCLUSIONES

El estudio completo sobre Cora confirma tres hallazgos: (i) las características relacionales manuales proporcionan una base competitiva, (ii) la validacion estadistica respalda la asociacion entre estructura de grafo y clase tematica, y (iii) el aprendizaje de representaciones latentes con Node2Vec produce la mejora de rendimiento mas relevante del proyecto.

El mejor baseline manual fue Arbol de Decision con *F1-macro=0.7588*, mientras que el modelo final kNN + Node2Vec alcanzo 0.8680 en test. Esta diferencia demuestra que comprimir un espacio binario muy disperso en embeddings densos de 64 dimensiones beneficia significativamente la separabilidad de clases.

Como trabajo futuro inmediato se plantea: comparar con GCN/GraphSAGE, ampliar evaluacion a otros datasets de citacion (por ejemplo CiteSeer y PubMed), y estudiar calibracion/probabilidades para despliegue en escenarios de soporte a revision bibliografica.

REFERENCIAS

- [1] P. Sen, G. Namata, M. Bilgic, L. Getoor, B. Gallagher, and T. Eliassi-Rad, "Collective Classification in Network Data," *AI Magazine*, vol. 29, no. 3, pp. 93-106, 2008.
- [2] S. Fortunato, "Community detection in graphs," *Physics Reports*, vol. 486, no. 3-5, pp. 75-174, 2010.
- [3] A. Grover and J. Leskovec, "node2vec: Scalable feature learning for networks," in *Proc. ACM SIGKDD*, 2016, pp. 855-864.
- [4] T. N. Kipf and M. Welling, "Semi-supervised classification with graph convolutional networks," in *Proc. ICLR*, 2017.
- [5] W. L. Hamilton, R. Ying, and J. Leskovec, "Inductive representation learning on large graphs," in *Proc. NeurIPS*, 2017, pp. 1024-1034.
- [6] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *JMLR*, vol. 12, pp. 2825-2830, 2011.
- [7] A. A. Hagberg, D. A. Schult, and P. J. Swart, "Exploring network structure, dynamics, and function using NetworkX," in *Proc. SciPy*, 2008, pp. 11-15.

- [8] M. E. J. Newman, *Networks: An Introduction*. Oxford, U.K.: Oxford Univ. Press, 2010.
- [9] D. Liben-Nowell and J. Kleinberg, "The link-prediction problem for social networks," *J. Amer. Soc. Inf. Sci. Technol.*, vol. 58, no. 7, pp. 1019-1031, 2007.
- [10] J. Tang, J. Zhang, L. Yao, J. Li, L. Zhang, and Z. Su, "ArnetMiner: Extraction and mining of academic social networks," in *Proc. ACM SIGKDD*, 2008, pp. 990-998.